

PREPROCESAMIENTO DE DATOS

PREPROCESAMIENTO DE DATOS PARA MACHINE LEARNING

DATASET BANK MARKETING

INTEGRANTES:
TOMAS ZAPATA
MAURICIO TAPIA
GABRIEL MUÑOZ

DOCENTE:
VICTOR TRIGO

OBJETIVO DEL PROYECTO

OBJETIVOS ESPECIFICOS

- Identificar y tratar datos faltantes.
- Aplicar técnicas de escalamiento a variables numéricas.
- Codificar variables categóricas.
- Generar nuevas variables mediante ingeniería de características.
- Construir un flujo reproducible de preprocesamiento.

DATASET Y FLUJO METODOLÓGICO

DATASET UTILIZADO

- 41.188 registros.
- 21 variables.
- Variable objetivo: y.
- Campañas de marketing telefónico de una institución bancaria.

Distribución de la Variable Objetivo

- No: 36.548 registros.
- Yes: 4.640 registros.



TRATAMIENTO DE DATOS FALTANTES

PROBLEMA DETECTADO

El dataset no presenta valores nulos explícitos, pero contiene registros con el valor: unknown

LOS PRINCIPALES ATRIBUTOS AFECTADOS FUERON:


- job
- education
- default
- housing
- loan

DECISIÓN APLICADA

unknown → NaN
para posteriormente imputar por moda.

JUSTIFICACIÓN

- Evitar pérdida innecesaria de registros.
- Mantener la representatividad del conjunto de datos.
- Obtener variables consistentes para etapas posteriores.



ELIMINACIÓN DE VARIABLE CON DATA LEAKAGE

VARIABLE ANALIZADA

PROBLEMA

Representa la duración total de la llamada telefónica.

Esta información solo se conoce una vez finalizada la interacción con el cliente.

RIESGO

Su utilización permitiría que el modelo acceda a información que no estaría disponible en un escenario real de predicción.

DECISIÓN

Eliminar la variable duration

BENEFICIO

- Evitar data leakage.
- Obtener modelos más realistas y generalizables.

ANÁLISIS EXPLORATORIO DE DATOS (EDA)

HALLAZGOS RELEVANTES

Distribución de la variable objetivo

- Predominio de respuestas negativas.
- Dataset desbalanceado.

DISTRIBUCIÓN DE EDAD


Mayor concentración entre 30 y 50 años.

NIVEL EDUCACIONAL

Predominio de educación secundaria y universitaria.

CONTACTOS PREVIOS

Gran parte de los clientes no posee historial previo de contacto.



ESCALAMIENTO DE VARIABLES NUMÉRICAS

PROBLEMA

Las variables presentan distintas escalas.

Variable	Rango aproximado
age	10 - 98
campaign	1 - 56
euribor3m	0 - 5

OBJETIVO

Transformar las variables para que tengan:

- Media = 0
- Desviación estándar = 1


BENEFICIOS

- Homogeneizar magnitudes.
- Mejorar el comportamiento de algoritmos de Machine Learning.
- Evitar que una variable domine a las demás.

TECNICA APLICADA

StandardScaler

ESCALAMIENTO ANTES/DESPUÉS



CODIFICACIÓN DE VARIABLES CATEGÓRICAS


PROBLEMA

Los algoritmos de Machine Learning no procesan directamente variables de texto.

RESULTADO

Transformación de variables categóricas a formato numérico interpretable por los algoritmos.

Variable	Tecnica
education	Ordinal Encoding
job	One-Hot Encoding
marital	One-Hot Encoding
housing	One-Hot Encoding
loan	One-Hot Encoding
contact	One-Hot Encoding
month	One-Hot Encoding
day_of_week	One-Hot Encoding
poutcome	One-Hot Encoding
y	Label Encoding



INGENIERÍA DE CARACTERÍSTICAS

OBJETIVO

Generar nuevas variables que aporten información adicional al modelo.

VARIABLE 1

contact_experience
= campaign + previous

Representa la experiencia acumulada de contacto con el cliente.

VARIABLE 2

was_contacted_before

Indica si el cliente había sido contactado anteriormente.

VARIABLE 3

economic_health
= emp.var.rate + euribor3m



Resume condiciones económicas generales.

VARIABLE 4

consumer_index
= cons.price.idx + cons.conf.idx

Representa el contexto económico percibido por los consumidores.

INGENIERÍA DE CARACTERÍSTICAS



PIPELINE DE PREPROCESAMIENTO



APLICACIÓN

- Ajuste únicamente con Train.
- Transformación consistente sobre Train y Test.

BENEFICIOS

- Reproducibilidad.
- Consistencia.
- Prevención de data leakage.

RESULTADOS DEL PREPROCESAMIENTO

Aspecto	Antes	Después
Valores faltantes	Si	No
Variables categóricas	Texto	Numéricas
Escalas distintas	Si	No
Nuevas variables	No	Si
Pipeline reproducible	No	Si

RESULTADO FINAL

Dataset preparado para etapas posteriores de modelado predictivo.

CONCLUSIONES

- Se identificaron y trataron correctamente los datos faltantes.
- Se eliminó la variable duration para evitar data leakage.
- Se aplicó escalamiento a variables numéricas mediante StandardScaler.
- Se codificaron las variables categóricas utilizando técnicas adecuadas.
- Se generaron nuevas variables mediante ingeniería de características.
- Se implementó una pipeline reproducible basada en Train/Test Split.
- El dataset quedó preparado para futuras etapas de Machine Learning.

GRACIAS POR VER